

学习笔记

专题一：提交内容

1.数据清洗和特征处理方法；

本项目采用了删除特征，根据特点填补缺失值，无量纲化的标准化，创造新特征的方法。具体描述如下：

- 删除特征：训练集中我删除了"PassengerId"（无效），"Name"（姓名中除了可以看出性别、年龄这些已知信息外，还可以反映出社会地位以及是否已婚等信息，但时间紧，且处理Name有点复杂，所以暂时舍弃，之后优化会加上），"Survived"（单独处理label以防止数据泄露），"Ticket"（编号可能隐藏一些信息，比如编号小的可能地位高实力强，但偶然性太大，故舍去），"Cabin"（客舱号缺失太多，且因为人员活动，如果补全并采用可能对模型造成误导，误差大）

- 根据特点填补缺失值：数值型采用中位数填补，如Age,Fare.(不用均值是因为均值受异常值的影响较大)。类别型采用众数填补（有多个众数时选择第一个）
- 无量纲化的标准化：一般对处理后的数据范围没有太严格的要求都选择标准化，而非归一化（标准化受极端异常值的影响较小）（这里有个疑惑，我尝试了筛选标准化之后的数据，显示有超过了【-10, 10】的区间的，但打印出来的部分序列数值都很小（没有异常数据））
- 创造新特征：利用SibSp, Parch合并成为了新的特征FamilySize, IsAlone这些数据可能反馈出，乘客可能因等待生存几率下降，或因互助让生存几率上升。（有了FamilySize，还要创造IsAlone是因为，模型不能清晰认识到独行的影响，FamilySize的1、2、3、4对模型来说是等差的，但其实1和2有着天差地别的差距，所以创造了IsAlone判断是否独行）
- 补充：本题没有异常数据，如果有，可采用如下方法，将异常值归为NaN，再和缺失值一起处理。（按理说如果要删异常值，应该要交叉验证一下(防止出现主观臆断)，并且记录一下哪些数据被删了，但是暂时还没学会）

代码 2

```
bad = (data['age'] < 0) | (data['age'] > 120)
data.loc[bad, 'age'] = np.nan
```

2.模型结构、损失函数、优化器及主要超参数

- 模型结构：利用nn.Module构造了一个深度学习的网络，采用了线性函数和激活函数结合，利用Dropout进行正则化（优化时还可以视情况加入L2正则化，还可以把一些删去的特征加上，并用L1正则化进行间接选择），一共有两个隐藏层（在设置模型时是没有设置输入层的）。实操时模型采用了先预测，再算Loss，再反向传播、结合Adam改参数（记得清除之前的梯度），训练完后关梯度，算测试集准确率

- 损失函数：是利用torch中的nn.CrossEntropyLoss（交叉熵损失），适合分类任务，可以在[PyTorch 官方 CrossEntropyLoss 文档] <https://pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html> 中查看细节（太多了，记不住）
- 优化器：运用Adam优化器（Adam 优化器是一个能为每个参数调整学习率，并且可以根据梯度进行动态调整的系数优化器。他结合了Momentum和RMSProp的优点）
- 主要超参数

超参数	取值	出处
隐藏层神经元数 h1 / h2	32 / 16	model.py
Dropout 率 p	0.32	model.py
学习率 lr	0.01	train.py
训练轮数 epochs	200	train.py
测试集比例	0.2	data.py TEST_RATE
随机种子	42	data.py / train.py
优化器	Adam	train.py

3.数据划分方式、随机种子和实验配置

- 数据划分方式:先将幸存和没幸存分开，打乱后，按训练集、测试集比例将幸存和没幸存划分，再相应地拼装在一起，最后再打乱一次。
- 随机种子：设定了固定种子——42，便于调试，消除部分偶然性
- 实验配置：(部分由ai生成)

1. 运行环境

项	值
操作系统	Windows 11
解释器	pycharm
Python	3.14.7
PyTorch	2.11.0+cu128
NumPy / pandas	2.5.2 / 3.0.5
matplotlib	3.11.1
实际计算设备	CPU (代码中未调用 <code>.cuda()</code>)

2. 产出文件

文件	说明
model/titanic.pth	模型权重
Training_loss_curve.png	训练损失曲线
Test_accuracy_curve.png	测试准确率曲线
titanic学习笔记.ipynb	学习笔记

3. 实验结果

指标	数值
首轮 loss	0.6234
末轮 loss	0.3314
最终测试准确率 (第 200 轮)	0.8023
全程最高测试准确率	0.8782
全猜遇难基线	0.6158
预测示例 (一等舱 25 岁女性)	预测幸存, 概率为 1.0000

4.训练过程中遇到的问题及解决方法

内容有些多，单独列了一个专题（见专题2）

5.测试集准确率、实验结果分析和心得体会

- 测试集准确率：可以达到80.23%
- 实验结果分析:损失有较明显的下降，但是精确度在后期也下降了（依然高于盲猜）。对于预测，有时他会给出概率为1的错误预测。可能是过拟合，或是噪音等问题。
- 心得体会：心得体会不多，但也单列了一个专题（见专题3）

专题二：训练过程中遇到的问题及解决方法

说明1：部分由ai生成，再由本人修改

说明2：这里只是部分，更多在源代码中有注释

问题	答案
<code>df: {__getitem__, copy}</code>	不是可执行代码，是"能力清单"：能 <code>df['列']</code> 取值、能 <code>.copy()</code>
<code>torch.tensor</code> 是什么	相当于 <code>np.array</code> ，但能上 GPU、能自动求梯度；是"预处理结果 → 网络"的桥
<code>dtype</code> vs <code>astype</code> 区别	<code>dtype</code> 是 属性 （查现在啥类型）； <code>astype</code> 是 方法 （返回改类型后的新数组）
<code>np.where(...)[0]</code> 的 <code>[0]</code>	<code>np.where</code> 返回"元组包数组"， <code>[0]</code> 把真正的下标数组剥出来，才能 <code>[:n]</code> 切片
<code>FEATURE_ORDER</code> 为何能固定顺序	<code>list</code> 有序 + <code>feats[ORDER]</code> 强制重排。网络只认"第几个输入口"，错位会 安静地算错
函数里的变量怎么搬出去	局部变量函数结束即销毁。正规做法： 一律用 return 传 （可返多个值/字典/对象）
环境/脚本定位	<code>os.path.dirname(os.path.abspath(__file__))</code> 拿脚本所在目录

2. 报错表（学长，放下屠刀，这个是ai根据我问他的问题生成的（所以也不太全），我修改成了我能看懂的样子，但我背不到啊~~~）

报错	原因	改法
KeyError: ['PassengerId'] not found	同一列被 drop 两次	只留一个 drop
KeyError: ['FamilySize'] not in index	FamilySize 是新创造的特征，却在创造前调用	改顺序
AttributeError: 'tuple' object has no attribute 'drop'	return self, df 打成元组，破坏赋值链	删掉 self
TypeError: int() ... not DataFrame	a.split(df) 多传的 df 被当 test_size	split 再接收一个 df 形参
TypeError: module() takes at most 2 arguments (3 given)	class Net(nn) —— nn 是模块不能继承	class Net(nn.Module)
TypeError: empty(): argument 'size' failed...	Net(nn.Module) 把类当维数传进去了	传整数 Net(ncol)
KeyError: ['FamilySize', 'Sex_male'] not in index	用原始 df 取新的特征	x = df2[ORDER].values.astype('float32')
IndexError: Target 1 is out of bounds	CrossEntropyLoss 要 2, 给的 1	模型输出改为2
Cannot assign modules before Module.__init__()	漏了 super().__init__()	__init__ 第一行补齐
ImportError: cannot import name 'draw'	函数的引用成环了	改成单向，main控制全部
mat1 and mat2 shapes cannot be multiplied (5x12 and 13x32)	喂了 12 维	特征按 ORDER 补齐 13 维
all the input array dimensions must match	concatenate 时拼不上（维度问题）	竖接看列数、横接看行数
'numpy.ndarray' object is not callable	.values() 多加了括号	.values 无括号
OMP: Error #15	torch 与 numpy 各带一份 OpenMP	main.py 首行 (import torch 之前) 设 os.environ['KMP_DUPLICATE_LIB_OK']='TRUE'

专题三：心得体会

关于知识的很多都在前面或是源代码里，这里就唠唠嗑了。经过多天的奋战，代码终于能跑通了，都是缺哪补哪，所以看着不太美观。也是学到了很多，包括以前用的不熟的python更熟了（虽然现在也经常漏这漏那），pytorch,numpy,pandas,matplotlib也零零散散的掌握了好多（不太系统就是了），反正还是挺有成就感的，虽然它现在是危墙，以后学的久了肯定能牢固（应该吧）。心得我就少写点了，节约学长时间（~~绝对不是手打了两万字已经累了~~）

专题四：优化方向

- 1. 处理Name特征
- 2. 视情况加一些方法：早停，L1正则（再给他几个舍弃的特征，让他帮我选）

3. 加入对GPU的选择使用
4. 改善精确度和损失
5. 将数据处理分为dataset和dataloader(分区更有界限些)
6. 多引进几个验证模型学习程度的图像, 参数 (混淆矩阵, recall等等)
7. (有些忘了)